TFM · Máster en Inteligencia Artificial · 2026

MermaOps

Sistema Multi-Agente de IA para la reducción de merma alimentaria en supermercados

Doce agentes de IA coordinados reducen la merma hasta un 40 % por 22-94 EUR/mes según tamaño. Sin fricción de adopción, con cumplimiento normativo CSRD 2026.

12
Agentes de IA coordinados

774/774
Tests automáticos · 100 %

22-94 EUR

23/23
Ataques adversariales bloqueados

30+
Comandos en Telegram

10-28:1
estimado

AUTOR
Álvaro Ferrer · alvaroferrermarg@gmail.com
linkedin.com/in/alvaro-ferrer-muro
+34 661 126 851

STACK
FastAPI · Supabase · Claude API · Flutter

01

VISIÓN TÉCNICA

Arquitectura del sistema

Un backend asíncrono orquesta doce agentes sobre Claude API, persiste en Supabase y se expone por dos interfaces sin fricción: bot de Telegram y app Flutter.

Diagrama de componentes

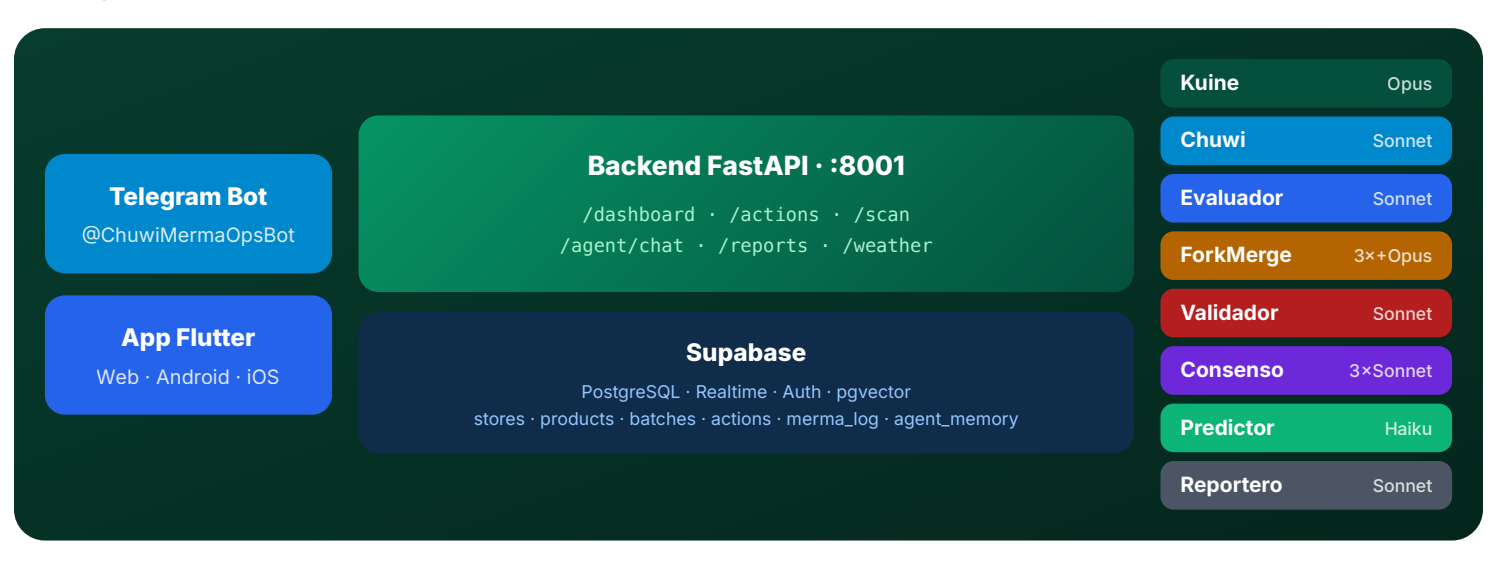

Stack tecnológico

CAPA	TECNOLOGÍA	VERSIÓN	DETALLE CLAVE
API	FastAPI + Uvicorn	Python 3.14	Puerto 8001, async, JWT auth
Agentes	Claude API (Anthropic)	Opus 4.7 · Sonnet 4.6 · Haiku 4.5	Right-sizing de modelo por tarea
Base de datos	Supabase PostgreSQL	pgvector 1536-dim	RLS por `store_id`, Realtime WS
App	Flutter + Dart	Riverpod + GoRouter	Web y móvil, ShellRoute
Telegram	python-telegram-bot	v21+	Polling, callbacks, inline keyboards
Scheduler	APScheduler	3.x	15 jobs cron, 07:00–21:30
Tests	pytest	774/774	< 2 s, sin conexión real a BD/API

Configuración y seguridad

> **PRINCIPIO DE SEGURIDAD**
> Ningún valor secreto vive en el código. Todo se gestiona por `.env` y nunca se sube al repositorio. RLS activado en todas las tablas por `store_id`.

`ANTHROPIC_API_KEY`	Acceso a Claude API
`SUPABASE_URL` · `KEY`	Proyecto y clave anónima
`SUPABASE_SERVICE_KEY`	Operaciones admin
`TELEGRAM_BOT_TOKEN`	Bot de Telegram

02

EL NÚCLEO DEL SISTEMA

Los doce agentes de IA

Diez agentes con LLM real y dos heurísticos de coste cero. Cada uno usa el modelo justo para su tarea: Opus para orquestar, Sonnet para razonar, Haiku para tareas rápidas.

AGENTE	MODELO	ACTIVACIÓN	TÉCNICA PRINCIPAL
Kuine · orquestador	Opus 4.7	07:30 / 12:00 / 20:00 / scan	Loop 20 iter, 16 tools, extended thinking
Chuwi · Telegram	Sonnet 4.6	Mensajes Telegram, streaming	Intent 0-token, reflexión, caching
Evaluador	Sonnet 4.6	Scan + tools de Kuine	Score 0–100, thinking si score 65–90
ForkMerge	3× Sonnet + Opus	Valor > 50 € o caducado	3 ramas paralelas + síntesis Opus
Validador	Sonnet 4.6	Pre-ejecución de toda acción	23 ataques adversariales · 100 %
Consenso	3× Sonnet 4.6	Score ≥ 90 y valor ≥ 30 €	3 instancias paralelas · regla 2/3
Predictor	Haiku 4.5	07:00 diario + petición	Open-Meteo + historial de merma
Visión	Haiku 4.5	Foto Telegram / scan app	Image understanding de producto
Reportero	Sonnet 4.6	Cierre diario / semanal	Síntesis de datos → brief + PDF
Notificador	python-tg-bot	Alertas scheduler 8–21 h	SLA tracking, escalaciones
Precio	Heurístico	Cada evaluación	Descuento lineal días × categoría · 0 tokens
Stock	Heurístico	Reposición de almacén	FEFO automático, umbral · 0 tokens

Cómo se reparte el trabajo

> **RIGHT-SIZING DE MODELO**
> El sistema no usa siempre el modelo más caro. **Opus 4.7** solo orquesta y sintetiza decisiones de alto impacto; **Sonnet 4.6** razona y conversa; **Haiku 4.5** resuelve predicción y visión. Dos agentes son puramente heurísticos: cuestan 0 tokens.

> **ESCALADA POR IMPACTO**
> Un yogur de 0,80 € con riesgo alto se resuelve con un solo evaluador. Un lote de 50 € o ya caducado activa **ForkMerge** (3 perspectivas) y, en casos extremos, **Consenso** (votación 2/3). El gasto se concentra donde hay dinero real en juego.

Fichas técnicas de los agentes clave

Kuine · orquestador principal — Claude Opus 4.7

El cerebro del sistema. Loop agéntico real: recibe el prompt, decide si necesita herramientas, las ejecuta, recibe resultados y decide si continuar o responder. Hasta 20 iteraciones, timeout de 5 min.

- **16 tools reales:** get_expiring_batches, evaluate_product_risk, create_action, calculate_discount, store_memory, recall_memory...
- **Extended thinking adaptativo** (sin límite) para el brief diario; budget de 1500 tokens para el scan rápido
- 3 flujos: `run_daily_brief` (07:30) · `run_intraday_check` (12:00) · `run_closing` (20:00)
- Memoria episódica en `agent_memory`: guarda decisiones, patrones y aprendizajes de la tienda

Chuwi · bot conversacional Telegram — Claude Sonnet 4.6

Agente conversacional en Telegram. Clasifica intenciones sin gastar tokens, precarga contexto de Supabase y decide si necesita el LLM o responde directo. Streaming real de la respuesta.

- **Intent 0-token:** 10 intenciones por palabras clave → ahorro ~60 % de llamadas al LLM
- **Prompt caching:** tools estáticos con TTL de 5 min → ahorro ~85 % de tokens
- **Reflexión loop** (Shinn 2023): aprende de cada interacción y guarda 5 lecciones en memoria

Evaluador — Sonnet 4.6

Calcula el riesgo de cada lote (0–100). El score fija la acción: crítico ≥ 85, alto ≥ 65, medio ≥ 40, bajo < 40.

- Thinking solo en la zona ambigua (65–90)
- Scores obvios: thinking off, −60 % tokens

ForkMerge — 3× Sonnet + Opus

Patrón fork-merge. Se activa con valor > 50 € o lote caducado: 3 ramas con perspectivas distintas → síntesis Opus.

- Clearance · Margin · Donation
- Deducción fiscal Ley 49/2002 (35 %)

Validador — Sonnet 4.6

Único agente que puede revertir a Kuine. 23 verificaciones adversariales, bloquea el 100 % en la suite (47/47).

- Bloquea prompt injection, precio < coste, caducidad falsa, FEFO...
- RAG: Reglamento CE 178/2002 vía pgvector

Consenso — 3× Sonnet 4.6

Casos extremos (score ≥ 90 y valor ≥ 30 €): tres instancias independientes deciden, pasa con 2/3.

- Doble umbral: solo impacto real lo activa
- 3 evaluadores en paralelo (ThreadPool)

03

INGENIERÍA DE AGENTES

Patrones multi-agente implementados

Cinco patrones de la literatura reciente, aplicados a un caso real con coste medido y tests que los validan.

3.1 · Loop agéntico de Kuine

> **REFERENCIA**
> Anthropic — *Building Effective Agents* (2024). Patrón orquestador-trabajadores.

1	**Prompt de entrada**	El sistema envía instrucciones + contexto de la tienda
2	**Claude analiza**	Opus 4.7 decide: ¿necesito herramientas? → sí / no
3	**Ejecutar tool**	get_expiring_batches() · evaluate_product_risk() · create_action()...
4	**Resultado a Claude**	El tool_result vuelve al modelo como mensaje
5	**Siguiente iteración**	Claude decide si necesita más tools (hasta 20)
6	**Respuesta final**	Brief / informe / acciones creadas en Supabase

3.2 · Fork-Merge — evaluación paralela de alto impacto

> **ACTIVACIÓN**
> `value_at_risk > 50 €` o `days_left ≤ 0` → ForkMerge sustituye al evaluador estándar.

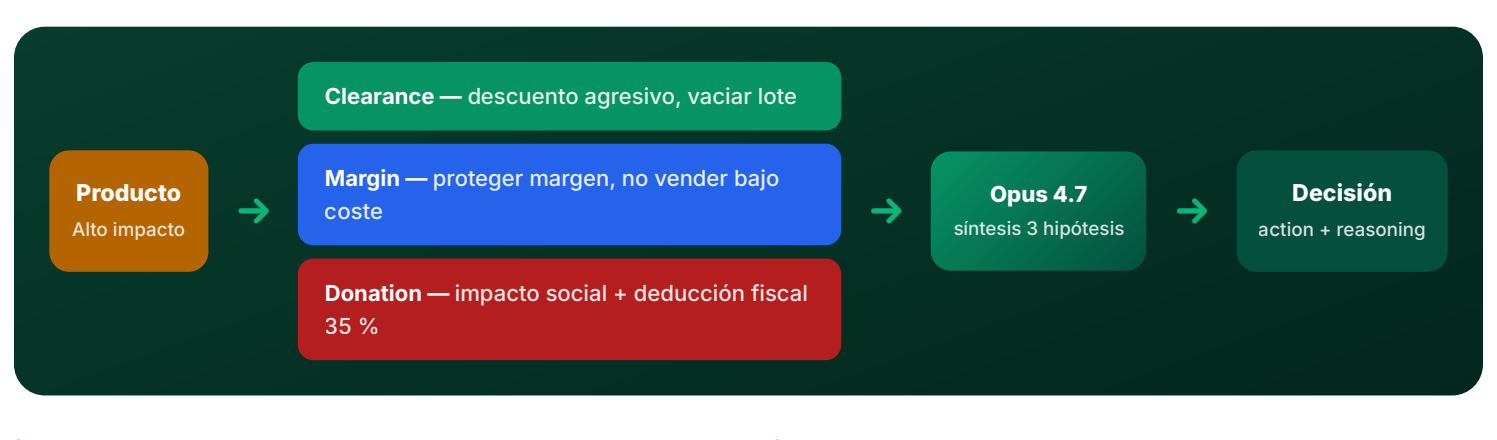
Producto
Alto impacto
Clearance — descuento agresivo, vaciar lote
Margin — proteger margen, no vender bajo coste
Donation — impacto social + deducción fiscal 35 %
Opus 4.7
síntesis 3 hipótesis
Decisión
action + reasoning

3.3 · Reflexión loop

> **REFERENCIA**
> Shinn et al. (2023) — *Reflexion: Language Agents with Verbal Reinforcement Learning.*

Tras cada interacción, Chuwi genera vía Haiku 4.5 (fire-and-forget): «¿qué aprendí? ¿qué haría diferente?». Las 5 lecciones más recientes se guardan en `agent_memory` y alimentan la siguiente sesión.

3.4 · Intent 0-token + caching

> **ROI DEL PROMPT CACHING**
> Brief diario (Opus, 8 iter): **0,48 €** sin caché → **0,058 €** con caché (−88 %)
> Sesión Chuwi (Sonnet, 6 turnos): **0,045 €** → **0,007 €** (−85 %)
> Mes completo (1 tienda): coste real medido 22-94 EUR/mes

04

INTERFAZ SIN FRICCIÓN

Bot Telegram · @ChuwiMermaOpsBot

El encargado ya tiene Telegram. Sin app nueva, sin formación, sin barrera de adopción: el agente trabaja donde el equipo ya está.

¿Por qué Telegram como interfaz?

El streaming visual (texto progresivo) muestra que el agente «piensa». Funciona en cualquier móvil sin instalar nada. El scheduler trabaja en autónomo y avisa sin que nadie pregunte.

- **Streaming real** — la respuesta aparece progresivamente
- **Inline keyboards** — botones de acción bajo cada mensaje
- **30+ comandos** — públicos, operativos y de manager
- **Modo ruta GPS** — guía acción por acción por pasillos
- **Alertas proactivas** — sin que nadie las pida

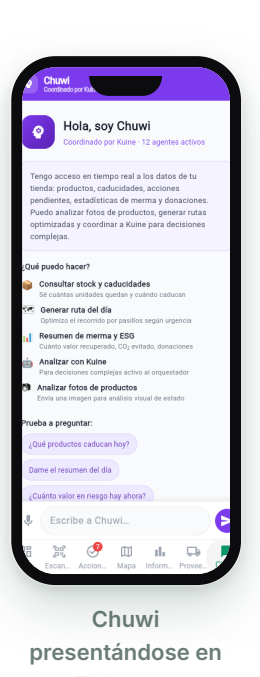
Chuwi presentándose en Telegram

Comandos disponibles

Públicos · sin login	
`/start`	Onboarding y menú principal
`/estado`	Semáforo verde / ámbar / rojo
`/agentes`	Estado de los 12 agentes
`/ayuda`	Guía completa con ejemplos

Manager · solo encargados	
`/pedido`	Pedido semanal por IA
`/esg`	ESG: CO_2, agua, CSRD 2026
`/insights`	Insights estratégicos (Sonnet)
`/simular`	Panel demo de simulación

Operativos · empleados	
`/acciones`	Pendientes por urgencia
`/criticos`	Solo score ≥ 85 (crítico)
`/ruta`	Ruta diaria por pasillos
`/brief`	Brief diario de Kuine
`/scan`	Escanear foto o barcode
`/mapa`	Productos por caducar, por zona

Scheduler — 15 trabajos autónomos (07:00–21:30)

HORA / FRECUENCIA	JOB	FUNCIÓN PRINCIPAL
07:00 diario	Predicción	Open-Meteo + historial → predicción a 7 días
07:30 diario	Brief diario	Kuine analiza la tienda y genera acciones
12:00 diario	Check mediodía	Escala si hay críticos sin resolver
20:00 diario	Cierre	Resumen del día y merma efectiva
Cada 30 min · 8–21 h	Monitor	Alertas proactivas con botones de donación inline

---

05

EXPERIENCIA MÓVIL

App Flutter · nueve pantallas

Para quien prefiere una interfaz visual completa: dashboard en tiempo real, gestión de acciones, plano de tienda e informes. Riverpod + Supabase Realtime.

Onboarding, login y dashboard

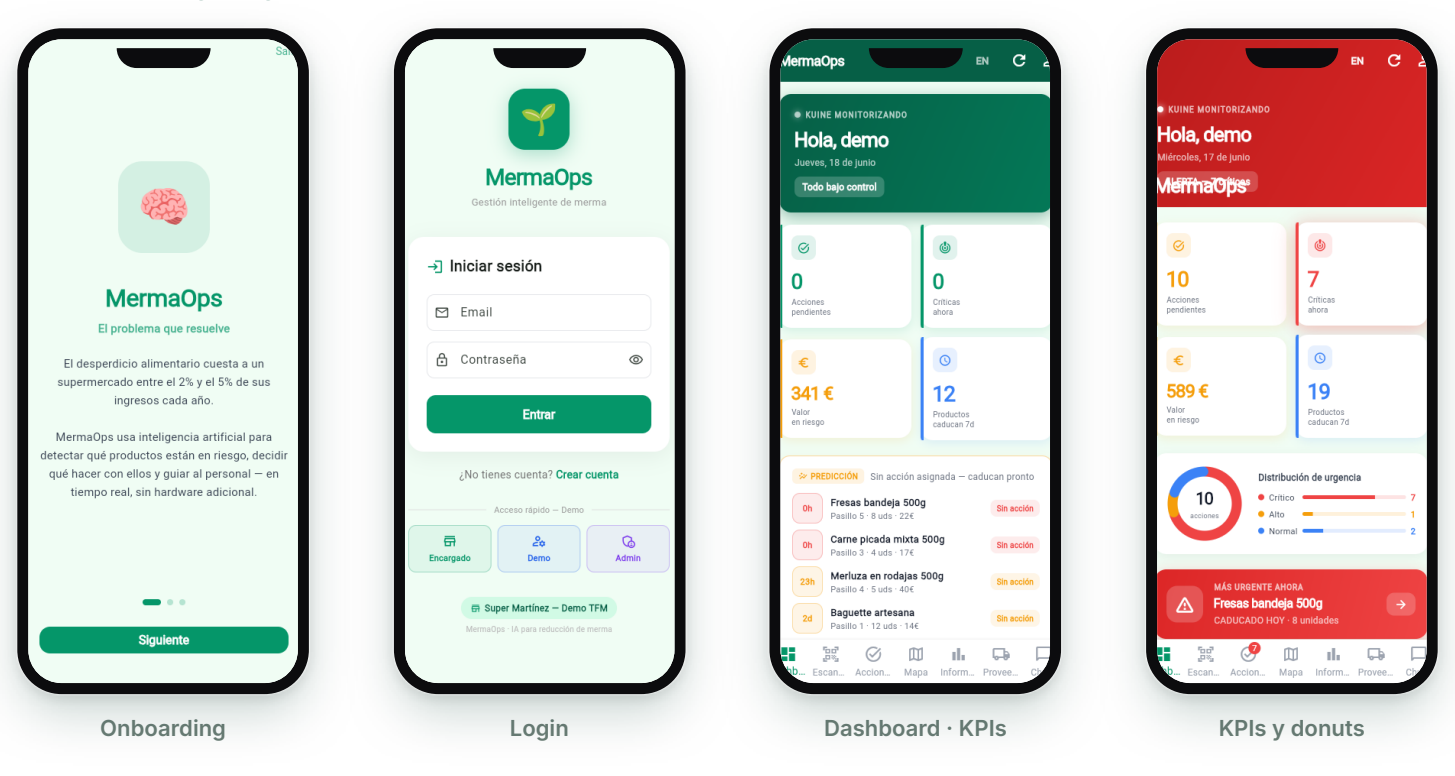
Onboarding · Login · Dashboard · KPIs · KPIs y donuts

- **KPIs en streaming** vía Supabase Realtime: acciones críticas, merma evitada, donaciones, valor en riesgo
- Donut chart de urgencia (crítico/alto/medio/bajo) + area chart de merma a 7 días
- Tarjeta del tiempo Open-Meteo y auto-refresh (5 min dashboard, 30 min clima); el badge de críticos se actualiza sin recargar

Acciones — gestión con swipe y exportación

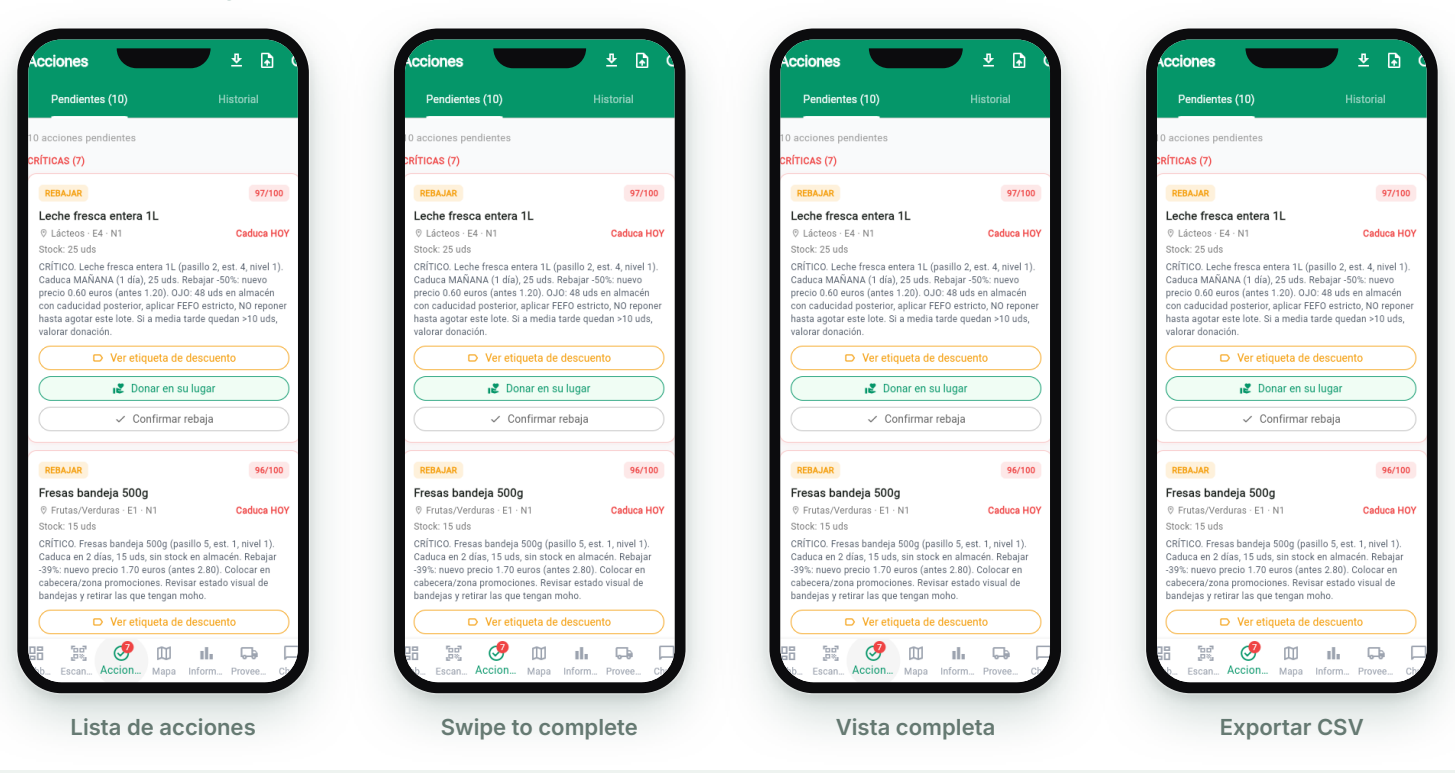
Lista de acciones · Swipe to complete · Vista completa · Exportar CSV

- **Swipe to complete** (solo rol manager); donación con cálculo fiscal 35 % automático al confirmar (Ley 49/2002)
- Export e import CSV desde TPV: `Share.shareXFiles` en web y móvil, parseo automático de lotes

---

Mapa y plano — CustomPainter con plano real

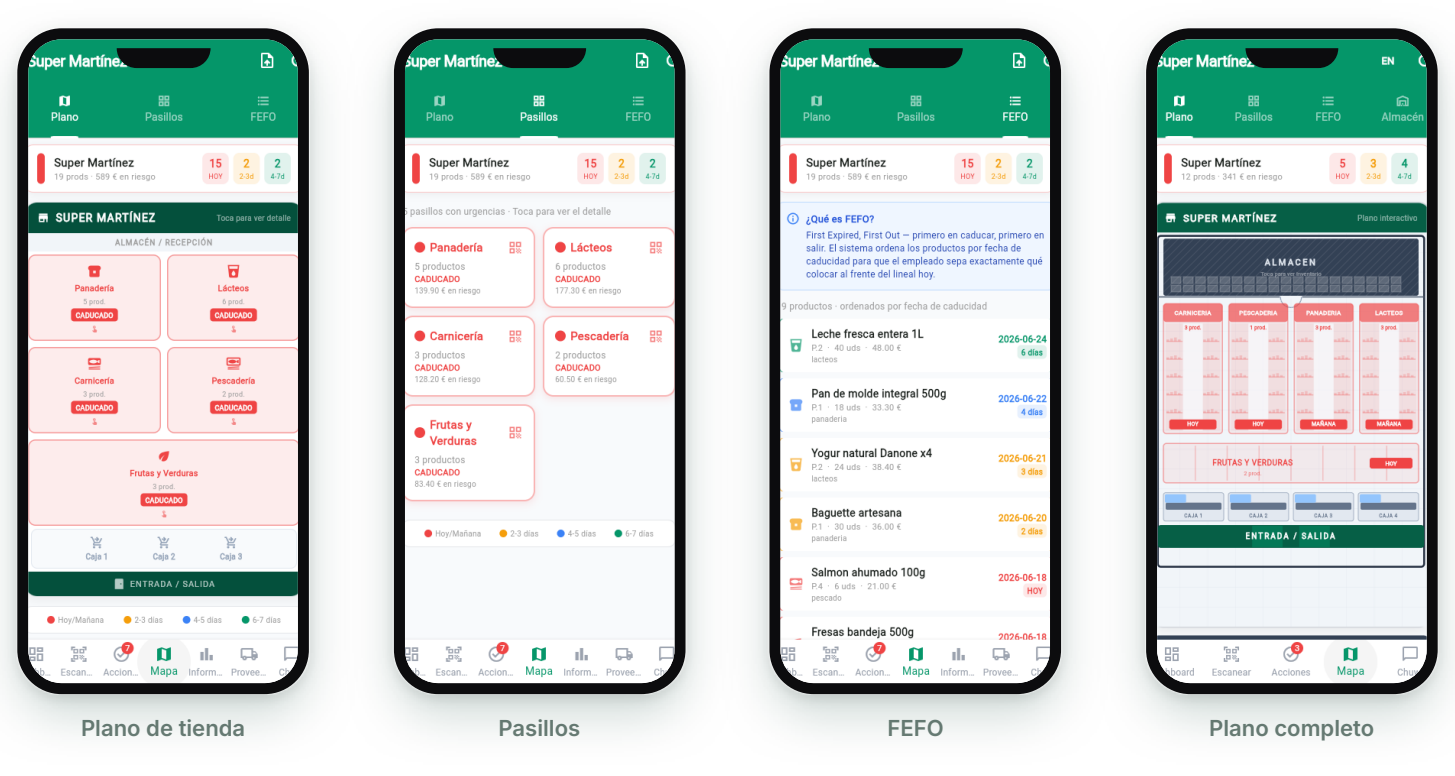
Plano de tienda · Pasillos · FEFO · Plano completo

- **Plano real dibujado con CustomPainter:** almacén, 4 pasillos, zona de frutas y verduras y cajas. Hit-testing: tap en zona → navegación
- **Tab FEFO:** lotes ordenados por fecha de caducidad (First Expired, First Out)

Informes — 11 pestañas con datos reales

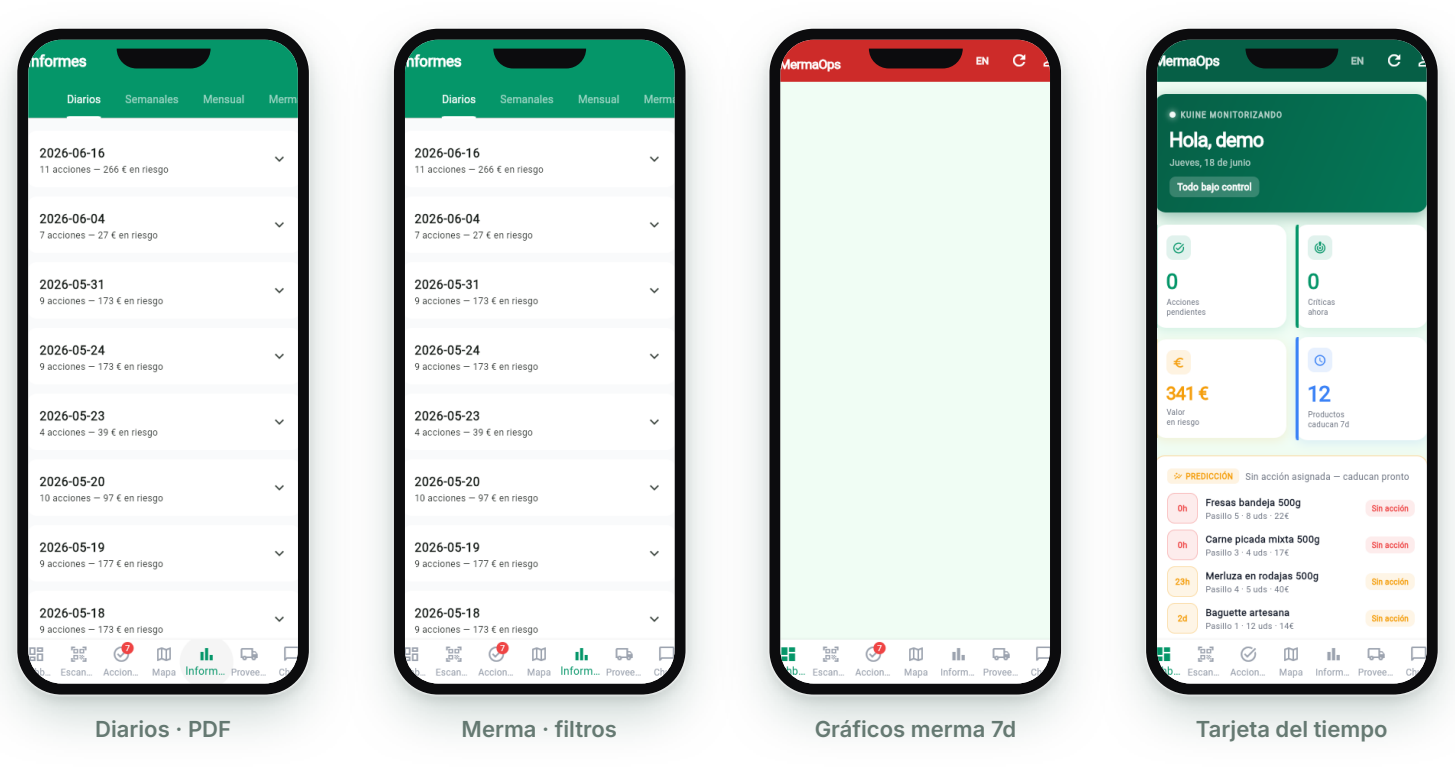
Diarios · PDF · Merma · filtros · Gráficos merma 7d · Tarjeta del tiempo

- **11 pestañas:** PDF brief, PDF semanal, merma, pedidos, ESG, predicciones, benchmark, proveedores, alternativas e insights IA
- Filtro de merma por razón con detalle por fila; los lotes FEFO se ordenan por fecha de caducidad real

---

Vista de escritorio · informes en web

La misma base Flutter se sirve en web para el manager: los informes ganan ancho y densidad de datos sin perder coherencia visual con la app móvil. Once pestañas reúnen todo el análisis de la tienda en un único panel.

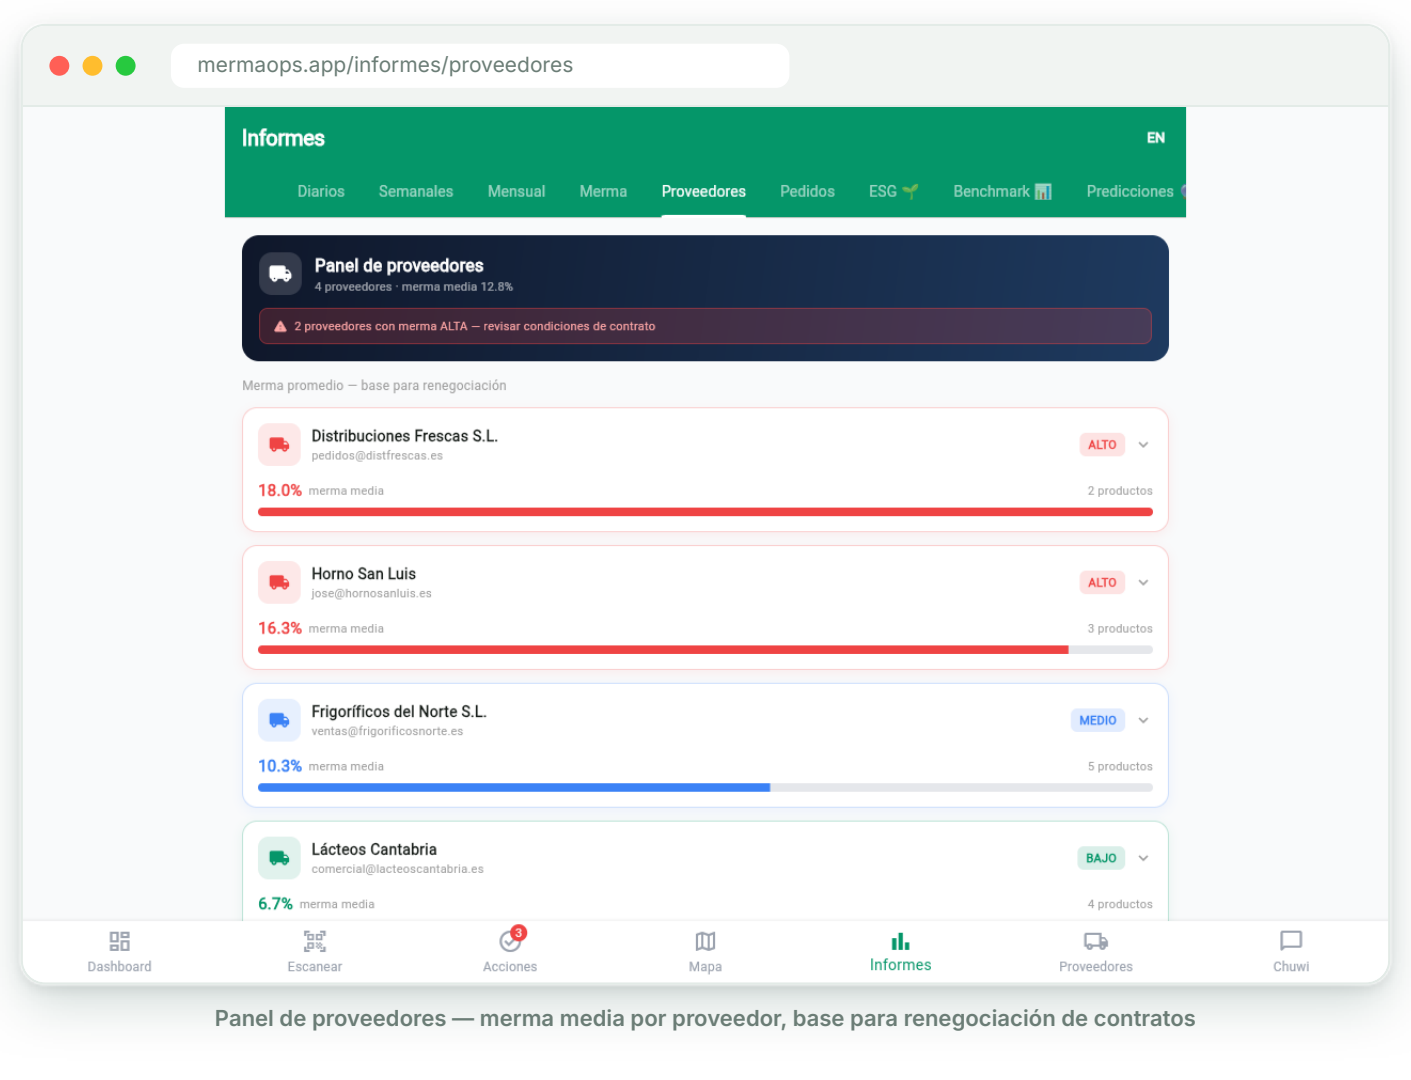

Panel de proveedores — merma media por proveedor, base para renegociación de contratos

Las 11 pestañas del panel de informes

- **Diarios y Semanales:** brief de Kuine exportable a PDF con un clic
- **Merma:** filtro por razón (caducidad, calidad...) con detalle por fila
- **Pedidos:** propuesta semanal generada por IA según rotación e histórico
- **Proveedores:** merma histórica cruzada por proveedor y categoría
- **ESG · CSRD 2026:** cada punto clicable con la normativa aplicable
- **Predicciones:** merma a 7 días con contexto climático de Open-Meteo
- **Benchmark:** comparativa frente a referencias del sector (WRAP, FAO)
- **Insights IA:** análisis estratégico generado con Sonnet 4.6 bajo demanda

> **MISMO CÓDIGO, DOS SUPERFICIES**
> App móvil para el operario en planta y panel web para el manager: ambas consumen el mismo backend y los mismos datos de Supabase en tiempo real, sin duplicar lógica.

06

MÉTRICAS VERIFICABLES

Resultados y métricas reales

Todos los datos son consultables en Supabase, tabla a tabla, sin estimaciones. La suite corre en menos de dos segundos sin conexión real a la BD ni a la API.

774/774
Tests · 100 % pass

23/23
Ataques adversariales bloqueados

483,95 €
Merma identificada

+83,3 pp
Precisión vs. baseline

45
Acciones completadas

22-94 EUR
Coste real / mes

Suite de tests por módulo

MÓDULO	TESTS	TIEMPO
Evaluador (score 0–100)	89/89	0,14 s
Validador (23 ataques)	47/47	0,08 s
Consenso (regla 2/3)	42/42	0,12 s
Supervisor / Kuine	25/25	0,19 s
Chuwi agent	61/61	0,31 s
Database & API	38/38	0,42 s
Scheduler	18/18	0,09 s
Otros módulos	454/454	0,63 s
TOTAL	774/774	1,98 s

Datos operativos reales

Acciones completadas por empleados	45
Briefs diarios generados por Kuine	7
Decisiones tomadas por Kuine	15
Valor de merma identificado	483,95 €
Valor donado (deducción 35 %)	69,40 €
Duración media por run de Kuine	~6,3 min
Coste mensual estimado (1 tienda)	22-94 EUR
ROI mensual (merma evitada / coste)	10-28:1

Comparativa con soluciones del mercado

CRITERIO	MERMAOPS	WINNOW V2	ORBISK	MANUAL
Coste implantación	0 €	> 20.000 €	> 15.000 €	0 €
Coste operativo / mes	22-94 EUR	~300 €	~250 €	~120 €
Hardware requerido	Ninguno	Báscula + cámara	Cámara + servidor	Ninguno
Autonomía 24/7	Sí · 15 cron	Parcial	Parcial	No
Normativa CSRD · multi-agente	Sí · 12 agentes	No	No	No

Desglose de costes API / mes (precios Anthropic 2025 + prompt caching -22%)

Componente	Med.	Peq. / Grande
Brief diario Kuine (Opus, 10 iter)	~32 EUR	~11 / ~50 EUR
Checks mediodía + cierre (Opus, 2/día)	~8 EUR	~3 / ~13 EUR
Sesiones Chuwi (Sonnet, avg 4/día)	~6 EUR	~2 / ~10 EUR
Predicciones + Visión (Haiku, diario)	~1 EUR	~0.5 / ~2 EUR
Reportes PDF + Insights (Sonnet)	~2 EUR	~1 / ~3 EUR
Descuento prompt caching (-22%)	-11 EUR	-4 / -17 EUR
TOTAL mensual (1 tienda)	60 EUR	22 / 94 EUR

Viabilidad económica por nº empleados (fuente: AECOC 2019, INE 2022)

Empl.	Factur./año	Merma/mes*	Ahorro/mes	Benef.neto/mes	ROI
3-8	~900K EUR	~656 EUR	~197 EUR	~175 EUR	~9:1
8-25	~4M EUR	~2.917 EUR	~875 EUR	~815 EUR	~15:1
25-80	~14M EUR	~10.208 EUR	~3.063 EUR	~2.969 EUR	~33:1

* Merma: 2,5% compras perecederas (AECOC 2019). Perecederos=35% facturación. Reducción 30% conservadora (MermaOps hasta 40%). Beneficio neto = ahorro - coste API.

MermaOps

Sistema Multi-Agente de IA para la reducción de merma alimentaria en supermercados

12 agentes IA
10 con LLM · 2 heurísticos

774/774 tests
< 2 s · sin API real

30+ comandos
Telegram · streaming

22-94 EUR/mes
Caching · ROI 10-28:1

- Loop agéntico (Kuine)
- Reflexión loop (Shinn 2023)
- Prompt caching
- Fork-Merge (Anthropic 2024)
- Intent 0-token
- Validación adversarial

CE 178/2002 · RD 1334/1999 · Ley 7/2022 · Ley 49/2002 · CSRD 2026

TFM — Máster en Inteligencia Artificial · 2026

Álvaro Ferrer · alvaroferrermarg@gmail.com

22-94 EUR/mes
+34 661 126 851 | linkedin.com/in/alvaro-ferrer-muro