

MÁSTER IA GENERATIVA & INNOVATION · EVOLVE MADRID 2026

MermaOps

Memoria Ejecutiva

Descripción técnica y académica del sistema

Álvaro Ferrer Muro · alvaroferrermarg@gmail.com

Memoria Ejecutiva

Descripción técnica y académica del sistema para el tribunal del TFM.

1. Problema y contexto

El desperdicio alimentario en supermercados españoles representa entre el **2% y el 5% de los ingresos anuales**. Un establecimiento mediano pierde entre 15.000 y 40.000 € al año en productos que caducan sin venderse. Las soluciones existentes (Winnow, Orbisk) cuestan más de 20.000 € de implantación y requieren hardware específico, lo que las hace inaccesibles para el 95% de los establecimientos. La gestión actual se realiza mediante inspección manual o Excel desconectado del inventario real.

2. Solución — MermaOps

MermaOps es un sistema multi-agente de IA construido sobre Claude API (Anthropic) que gestiona la merma alimentaria desde el móvil del encargado, sin hardware adicional, con un coste operativo de **0,80 €/mes**. El sistema tiene dos interfaces:

- **Telegram** (@ChuwiMermaOpsBot): el agente Chuwi responde en lenguaje natural, monitoriza la tienda cada 30 minutos y envía alertas proactivas sin que nadie pregunte.
- **App Flutter** (web + móvil): dashboard con KPIs, gestión de acciones, panel de agentes, informes PDF y métricas ESG.

3. Arquitectura — 12 agentes especializados

Agente	Modelo	Rol	Técnica clave
Kuine	Opus 4.7	Orquestador principal	ReAct loop, 20 iter, 16 tools
Chuwi	Sonnet 4.6	Agente conversacional	Intent classif., streaming, RAG
Evaluator	Sonnet 4.6	Score riesgo 0–100	Extended thinking adaptativo
ForkMerge	3×Sonnet+Opus	Fork-merge casos críticos	3 ramas paralelas, síntesis
Consenso	3×Sonnet	Decisión por mayoría 2/3	3 instancias concurrentes
Validador	Sonnet 4.6	Seguridad adversarial	23 vectores de ataque
Predictor	Haiku 4.5	Riesgo futuro 7 días	Open-Meteo API + historial
Visión	Haiku 4.5	Análisis de fotos	Multimodal, base64
Precio	Heurístico	Cálculo de descuentos	Sin LLM, 0 tokens
Stock	Heurístico	Decisiones FEFO	Sin LLM, 0 tokens
Notificador	Sonnet 4.6	Alertas proactivas	Telegram API, scheduling
Reportero	Sonnet 4.6	Briefs y PDFs	Citations, PDF generator

4. Decisiones técnicas justificadas

Right-sizing de modelos

No tiene sentido usar Opus para calcular un porcentaje de descuento. Opus solo donde hay máxima complejidad (Kuine). Haiku para tareas simples. Heurístico donde no hace falta LLM. Ahorro estimado: ~70% vs. usar Opus en todo.

Extended thinking adaptativo

El Evaluador activa thinking:adaptive solo para scores en zona de ambigüedad (65–90). Para scores obvios (>90 o <30) lo desactiva. Resultado: misma precisión con ~60% menos de tokens de thinking.

Validador adversarial

Sin el Validador, un input construido maliciosamente puede hacer que Kuine venda un producto caducado o done a una entidad no verificada. El Validador bloquea 23 vectores de ataque antes de ejecutar cualquier acción en el mundo real.

Telegram como interfaz principal

El encargado ya tiene Telegram instalado. Sin app nueva, sin formación, sin fricción de adopción. El streaming visual (texto que aparece progresivamente) da retroalimentación de que el agente está pensando.

Prompt caching

El system prompt de Kuine (~4.000 tokens) y las definiciones de herramientas (~5.000 tokens) se marcan con cache_control:ephemeral. Cada llamada posterior reutiliza el caché → ahorro de ~70% en tokens de entrada. Coste por brief: ~0,03 € en lugar de ~0,10 €.

5. Cumplimiento normativo

Normativa	Cobertura en MermaOps
Reglamento (CE) 178/2002 — seguridad alimentaria	Validador: nunca vender caducado
RD 1334/1999 — etiquetado y caducidad	Evaluador: días restantes exactos
Ley 7/2022 — residuos y economía circular	RAG + módulo ESG metrics
Ley 49/2002 — deducción fiscal donaciones (35%)	Módulo donaciones: cálculo automático
CSRD 2026 — reporting ESG PYMES	Módulo ESG: datos listos para reporting

6. Limitaciones y líneas futuras

MermaOps **no reemplaza al encargado**: todas las decisiones pasan por confirmación humana. No actúa en el mundo físico de forma autónoma. No accede a sistemas POS/ERP sin integración explícita. Esta delimitación es intencional y demuestra madurez técnica.

Líneas futuras prioritarias:

- Agente Comprador: predecir el pedido óptimo semanal cerrando el ciclo completo.
- Multi-tienda: comparativas por zona geográfica (arquitectura ya preparada).
- Integración TPV: validar que las rebajas registradas realmente se vendieron.
- Fine-tuning: con suficientes decisiones históricas, sustituir el Evaluador por un modelo propio.