


MermaOps

Sistema Multi-Agente de IA
para Reduccion de Merma Alimentaria
en Supermercados Espanoles



12

Agentes IA

774

Tests 100%

30+

Cmds Telegram

9

Pantallas App

0.80

EUR/mes

23/23

Seg. adversarial

Backend

FastAPI + Python 3.14 | Puerto 8001

IA

Claude Opus 4.7 / Sonnet 4.6 / Haiku 4.5

BD

Supabase PostgreSQL + Realtime + pgvector

App

Flutter Web + Android/iOS | Riverpod

01 - Arquitectura del Sistema

Diagrama de componentes



Stack tecnologico

Capa	Tecnologia	Version	Detalle clave
API	FastAPI + Uvicorn	Python 3.14	Puerto 8001, async, JWT auth
Agentes	Claude API Anthropic	Opus 4.7 / Sonnet 4.6 / Haiku	Right-sizing por tarea
BD	Supabase PostgreSQL	pgvector 1536 dim	RLS por store_id, Realtime WS
App	Flutter + Dart	Riverpod + GoRouter	Web + Android/iOS, ShellRoute
Telegram	python-telegram-bot	v21+	Polling, callbacks, inline keyboards
PDF	fpdf2	2.x	6 tipos de PDF server-side
Scheduler	APScheduler	3.x	15 jobs cron 07:00-21:30
Clima	Open-Meteo API	Gratuita	Sin API key, coordenadas GPS tienda
Tests	pytest	774/774	< 2s, sin conexion real BD/API
RAG	pgvector	1536 dim	Normativa alimentaria indexada

Variables de entorno requeridas

Seguridad

Ningun valor secreto en codigo. Todo gestionado por .env. Nunca subir .env al repositorio.

Variable	Ejemplo	Uso
ANTHROPIC_API_KEY	sk-ant-...	Acceso a Claude API (Opus/Sonnet/Haiku)

SUPABASE_URL	https://XXXX.supabase.co	URL del proyecto Supabase
SUPABASE_KEY	sb_anon_...	Clave anonima para operaciones de cliente
SUPABASE_SERVICE_KEY	sb_service_...	Clave de servicio para operaciones admin
TELEGRAM_BOT_TOKEN	123456:ABC...	Token del bot @ChuwiMermaOpsBot
STORE_ID	demo-store-001	Identificador unico de la tienda
APP_PORT	8001	Puerto del backend (8000 bloqueado por Manager.exe)

02 - Los 12 Agentes de IA

Resumen de los 12 agentes

Agente	Modelo	Activacion	Tecnica principal
Kuine (orquestador)	Opus 4.7	07:30 / 12:00 / 20:00 / scan	Loop 20 iter, 16 tools, extended thinking
Chuwi (Telegram)	Sonnet 4.6	Msgs Telegram, streaming	Intent 0-token, reflexion, caching
Evaluator	Sonnet 4.6	Scan + Kuine tools	Score 0-100, thinking >= score 65
ForkMerge	3xSonnet + Opus	Valor>50EUR o caducado	3 ramas paralelas + sintesis Opus
Validador	Sonnet 4.6	Pre-ejecucion toda accion	23 ataques adversariales, 100%
Consenso	3x Sonnet	Score>=90 Y valor>=30EUR	3 instancias paralelas, regla 2/3
Predictor	Haiku 4.5	07:00 diario + peticion	Open-Meteo API + historial merma
Vision	Haiku 4.5	Foto Telegram / scan app	Image understanding, analisis producto
Reportero	Sonnet 4.6	Cierre diario / semanal	Sintesis datos -> brief + PDF
Notificador	python-tg-bot	Alertas scheduler 8-21h	SLA tracking, escalaciones
Precio	Heuristico	Cada evaluacion	Descuento lineal dias x categoria (0 tokens)
Stock	Heuristico	Reposicion almacen	FEFO automatico, umbral configurable (0 tokens)

Descripcion tecnica detallada

KUINE - Orquestador principal

Claude Opus 4.7

El cerebro del sistema. Loop agentico real: recibe prompt, decide si necesita tools, las ejecuta, recibe resultados, decide si continuar o dar respuesta final. Hasta 20 iteraciones, timeout 5 min. Analiza la tienda entera: caducidades, stock, historial, normativa. Genera acciones concretas.

- 16 tools reales: get_expiring_batches, evaluate_product_risk, create_action, calculate_discount, get_warehouse_stock, search_food_regulations, store_memory, recall_memory, get_roi, evaluate_all_products_parallel...
- Extended thinking ADAPTATIVO (sin limite de tokens) para brief diario. Budget 1500 tokens para scan rapido
- 3 flujos principales: run_daily_brief (07:30) | run_intraday_check (12:00) | run_closing (20:00)
- ThreadPoolExecutor para evaluate_all_products_parallel: evalua todos los lotes en paralelo
- Memoria episodica en agent_memory: guarda decisiones, patrones, aprendizajes de la tienda

CHUWI - Bot Telegram conversacional

Claude Sonnet 4.6

Agente conversacional en Telegram. Clasifica intents sin tokens (palabras clave), precarga contexto de Supabase, decide si necesita LLM o responde directo. Streaming real: texto progresivo en Telegram.

- Intent classification 0-token: 10 intents por keywords -> ahorro ~60% llamadas LLM
- Prompt caching: tools estaticos TTL 5min -> ahorro ~85% tokens cached vs. sin cache
- Reflexion loop (Shinn 2023): aprende de cada interaccion, guarda 5 lecciones en agent_memory
- 30+ comandos: /menu /criticos /ruta /brief /scan /mapa /historial /merma7 /tiempo /esg /insights...
- Modo ruta activa: guia empleado accion por accion (GPS de tienda), avanza al confirmar/donar

EVALUADOR - Score de riesgo 0-100

Claude Sonnet 4.6

Calcula el riesgo de cada lote. Score 0=sin riesgo, 100=caducado hoy con stock alto. El score determina la accion: CRITICO >=85, ALTO >=65, MEDIO >=40, BAJO <40.

- Extended thinking ACTIVADO solo para scores 65-90 (zona de ambigüedad, decision puede cambiar)
- Para scores obvios (>90 o <30): thinking desactivado -> misma precision con ~60% menos tokens thinking
- Output: {risk_level, action, price_adjustment_pct, reasoning, thinking_used: bool}

FORKMERGE - Evaluacion paralela alto impacto

3x Sonnet 4.6 + Opus 4.7 sintesis

Patron fork-merge (Anthropic 2024). Activa cuando value_at_risk > 50 EUR o lote ya caducado. 3 ramas paralelas con perspectivas distintas -> sintesis por Opus.

- Rama 'clearance': maximizar sell-through, descuento agresivo para vaciar lote
- Rama 'margin': proteger margen bruto, no vender bajo coste de adquisicion
- Rama 'donation': impacto social + deduccion fiscal Ley 49/2002 (35%)
- Opus sintetiza las 3 hipotesis y elige la mas solida con justificacion estructurada

VALIDADOR - Seguridad adversarial

Claude Sonnet 4.6

El unico agente que puede REVERTIR decisiones de Kuine. Se ejecuta antes de cualquier accion real. 23 verificaciones adversariales. Bloquea 100% de ataques en suite de tests (47/47).

- Tipos de ataque bloqueados: prompt injection, precio < coste, caducidad falsificada, entidad donacion no verificada, violacion FEFO, escalada injustificada, action type invalido...
- Output: VALIDADO | CORREGIDO | RECHAZADO + final_action + explanation
- Integracion RAG: Reglamento CE 178/2002 consultado via pgvector antes de cada decision

CONSENSO - Votacion 3 instancias paralelas

3x Claude Sonnet 4.6

Para casos extremos (score >= 90 Y valor >= 30 EUR), tres instancias independientes analizan el mismo producto. La decision pasa si al menos 2/3 coinciden. En empate, Opus actua como arbitro.

- Doble umbral deliberado: yogur de 0,80 EUR con score 92 NO activa consenso. Solo impacto real
- 42/42 tests del modulo consenso al 100% (regla 2/3 correctamente implementada)
- Latencia aceptable: 3 evaluadores corren en PARALELO (ThreadPoolExecutor, no secuencialmente)

03 - Patrones Multi-Agente Implementados


3.1 Loop agentico de Kuine (Orchestrator-Workers)

Referencia
Anthropic - Building Effective Agents, 2024. Patron: Orchestrator-Workers.

[1] Prompt entrada	Sistema envia instrucciones + contexto tienda
[2] Claude analiza	Opus 4.7: necesito tools? -> SI NO
[3] Ejecutar tool	get_expiring_batches() / evaluate_product_risk() / create_action()...
[4] Resultado a Claude	tool_result devuelto al modelo como mensaje
[5] Siguiente iteracion	Claude decide si necesita mas tools (hasta 20 iter)
[6] Respuesta final	Brief / Informe / Acciones creadas en Supabase

3.2 Fork-Merge - Evaluacion paralela de alto impacto

Activacion
value_at_risk > 50 EUR O days_left <= 0 -> ForkMerge sustituye al Evaluador estandar



3.3 Reflexion Loop - aprendizaje continuo

Referencia
Shinn et al. (2023) - 'Reflexion: Language Agents with Verbal Reinforcement Learning'

Despues de cada interaccion con Evaluador/Vision, Chuwi genera via Haiku 4.5 (fire-and-forget): 'Que aprendi de esta interaccion? Que haria diferente?' Las 5 lecciones mas recientes se guardan en agent_memory y se incluyen en el system_prompt de la siguiente sesion.

3.4 Intent 0-token + Prompt Caching


Intent	Keywords detectadas	Contexto precargado
consulta_estado	estado, cuantos, que hay, muestrame	Conteo acciones criticas/altas
pedir_brief	brief, resumen, informe, analisis	Fecha + valor riesgo ultimo brief
completar_accion	completado, hecho, ya, listo	Top 3 acciones por prioridad
pedir_ruta	ruta, recorrido, por donde empiezo	Top 3 acciones por prioridad
registrar_donacion	donacion, banco alimentos, donar	Stats donaciones del mes
registrar_merma	tirar, caducado, se ha puesto malo	LLM fallback (dialogo necesario)
otros	[ninguna keyword coincide]	LLM fallback completo

ROI del Prompt Caching

Brief diario (Opus, 8 iter): sin cache ~0,48 EUR | con cache ~0,058 EUR -> ahorro 88%
Sesion Chuwi (Sonnet, 6 turnos): sin cache ~0,045 EUR | con cache ~0,007 EUR -> ahorro 85%
Mes completo (1 tienda): coste real medido ~0,80 EUR con caching activo

04 - Bot Telegram @ChuwiMermaOpsBot

Interfaz conversacional en Telegram



Chuwi en accion

Por que Telegram como interfaz?

El encargado ya tiene Telegram instalado. Sin app nueva, sin formacion, sin friccion de adopcion. El streaming visual (texto progresivo) muestra que el agente 'piensa'. Funciona en cualquier movil sin instalar la app Flutter.

Streaming real	texto aparece progresivamente
Inline keyboards	botones bajo cada mensaje
30+ comandos	publicos + operativos + manager
Modo ruta GPS	guia accion por accion
Alertas proactivas	sin que nadie pregunte
Scheduler 15 jobs	cron 07:00-21:30 autonomo

Comandos disponibles

Publicos - sin login	
/start	Onboarding completo con presentacion del sistema y menu principal
/yo	Perfil: nombre, rol (staff/manager), tienda asignada
/menu	Menu principal con botones inline a todas las funciones
/estado	Semaforo tienda: verde/amarillo/rojo segun criticos pendientes
/ayuda	Guia completa de todos los comandos con ejemplos
/agentes	Estado 12 agentes: activo/inactivo, modelo, ultimo run
/kuine	Info detallada Kuine: tools, runs recientes, iteraciones
Operativos - empleados	
/acciones	Lista pendientes por urgencia. Cada una con botones Confirmar/Donar/Escalar
/criticos	Solo acciones score >= 85 (CRITICO). Vista rapida urgente
/ruta	Ruta diaria optimizada por pasillos. Boton 'Iniciar modo ruta guiada'
/brief	Brief diario de Kuine. Genera o recupera el mas reciente
/hoy	Resumen del dia: ventas estimadas, merma, acciones, donaciones
/scan	Escanear: foto o barcode. Vision + Kuine -> accion
/merma	Registrar merma manualmente: producto deteriorado o caducado
/donaciones	Resumen donaciones mes + flujo guiado nueva donacion
/prediccion	Prediccion merma 7 dias (Haiku + Open-Meteo)

/mapa	Mapa por pasillos: productos proximos a caducar por zona
/historial	Acciones completadas ultimos 7 dias con empleado y tipo
/merma7	Proyeccion merma a 7 dias basada en caducidades proximas
/tiempo	Tiempo actual tienda (Open-Meteo) + prevision 5 dias

Manager - solo encargados	
/proveedores	Ficha proveedores con merma historica por categoria
/pedido	Pedido semanal generado por IA: rotacion + merma historica
/esg	Informe ESG: CO2, agua, donaciones, CSRD 2026
/costes	Analisis costes: merma por categoria, evolucion semanal
/reflexiones	Lecciones aprendidas del reflexion loop de Chuwi
/informe	Informe completo del mes: todas las metricas
/semana	Resumen semana: tendencias vs. semana anterior
/insights	Insights IA estrategicos (Sonnet 4.6)
/simular	Panel demo: 5 botones para simular brief/check/cierre/alerta/escalacion

Scheduler - 15 trabajos autonomos (07:00-21:30)

Autonomia total

El scheduler corre independientemente. Kuine analiza, notifica y escala sin que nadie lo active. El notificador NUNCA silencia mensajes en horario 8-21h.

Hora / Frec.	Job	Funcion principal
07:00 diario	Prediccion	Open-Meteo + historial merma -> prediccion 7 dias con contexto climatico
07:28 diario	Saludo	Mensaje proactivo de buenos dias con resumen de acciones pendientes
07:30 diario	Brief diario	Kuine run_daily_brief: analisis completo tienda, genera acciones
12:00 diario	Check mediodia	Kuine run_intraday_check: escala si hay criticos sin resolver
16:00 diario	Reflexion	Retrospectiva: que fue bien, que se puede mejorar hoy
20:00 diario	Cierre	Kuine run_closing: resumen real del dia, merma efectiva
Lunes 06:00	Semanal	Informe semanal completo + PDF adjunto en Telegram
Dia 1 08:00	Mensual	Informe mensual completo + PDF adjunto
Cada 2h 8-20h	Escalacion	Escala acciones score>=85 sin resolver mas de 4 horas
Cada 30min 8-21h	Monitor	Alertas proactivas con botones donacion inline
Cada 15min 8-20h	SLA check	Verifica que acciones criticas tienen respuesta en tiempo
Cada 30min 8-21h	Spike	Auto-brief si se detecta pico de acciones criticas nuevas
Cada 30min 8-21h	Triggers	Evalua intents automaticos segun contexto de la tienda
21:30 diario	Anomalias	Detecta patrones anomalos en inventario nocturno
9h / 13h / 18h	Health	Verifica conexion BD, bot Telegram, agentes activos

Flujo modo ruta activa (GPS de tienda)

- Activar

Escribe 'iniciar ruta' / 'modo ruta' o pulsa boton 'Iniciar modo ruta guiada'
- Primera accion

Muestra tarjeta: producto, pasillo-estanteria-nivel, urgencia, accion
- Empleado actua

Pulsa Confirmar / Donar entidad / Escalar segun tipo de accion
- Sistema registra


complete_action() en Supabase + log merma + SLA dismissed
- Avance automatico

Modo ruta detecta estado route_active y muestra siguiente accion
- Fin ruta

Cuando no quedan acciones: 'RUTA COMPLETADA: X completadas, Y saltadas'


05 - App Flutter: Onboarding y Dashboard

Onboarding y Login




El onboarding explica el sistema en 3 pasos. El login usa Supabase Auth con JWT. Tras el login, el rol (staff/manager) se lee del perfil y controla el acceso a features.

Dashboard - KPIs en tiempo real




- KPIs streaming Supabase Realtime: acciones_criticas, merma_evitada, donaciones, valor_riesgo
- Shimmer loading mientras carga. StreamProvider Riverpod con asyncMap
- Donut chart de urgencia (critico/alto/medio/bajo) + Area chart merma 7 dias
- Tarjeta del tiempo Open-Meteo: temperatura, icono WMO, prevision 5 dias
- Auto-refresh: 5 min dashboard, 30 min weather. Badge criticos actualiza sin recargar (Realtime WS)

Acciones - Gestion con swipe y export



- Swipe to complete: DismissDirection.endToStart, solo rol manager (staff ve pero no puede)
- Donacion con calculo fiscal 35% automatico (Ley 49/2002) al confirmar
- Export CSV: Share.shareXFiles con XFile.fromData (funciona en web y movil)
- Import CSV desde TPV: POST /api/v1/import/batches con parseo automatico
- Filtro por tipo (rebajar/donar/retirar/revisar) y urgencia (critico/alto/medio)

Mapa / Plano - CustomPainter con plano real




Plano tienda



Tab Pasillos




Tab FEFO



Plano completo


- Plano real dibujado con CustomPainter: almacen + 4 pasillos + Frutas&Verduras + cajas
- Hit-testing via _floorPlanRects: tap en zona -> navegacion. Tap almacen -> pantalla Almacen
- Tab Pasillos: lista por pasillo con QR y boton Cerrar correcto (dlgCtx, no parent context)
- Tab FEFO: lotes ordenados por fecha caducidad (First Expired First Out)
- Tab Plano: tarjeta inline Almacen con datos reales del backend (items, valor, alertas)

Escanear - Camara web + Vision Agent IA




- Web: mobile_scanner v6.0.2, Chrome 83+ / Edge (BarcodeDetector API nativa del navegador)
- Dialog.fullscreen: back button + overlay verde esquinas + deteccion automatica del codigo
- Movil: CameraFacing.back con permiso de camara automatico (Android/iOS)
- Vision Agent (Haiku 4.5): analiza foto y devuelve nombre, caducidad y recomendacion
- POST /api/v1/scan -> Kuine -> Evaluador -> accion creada automaticamente en Supabase


Informes - 11 tabs con datos reales




Diarios PDF



Merma filtros




ESG CSRD



Predicciones

- 11 tabs: PDF brief, PDF semanal, Merma, Pedidos, ESG, Predicciones, Benchmark, Proveedores, Alternativas, Insights IA
- Merma tab: filtro por razon (Todos/Caducidad/Calidad...) + dialog detalle por fila clicable
- ESG CSRD 2026: cada punto clicable con informacion de normativa aplicable
- Benchmark: badge 'Datos reales del backend' + ranking competidores con explicacion clicable
- Insights IA: POST /api/v1/reports/insights (Sonnet 4.6) generado con boton 'Generar'

Resto de pantallas: Agentes, Proveedores, Almacen, Perfil



Pantalla	Riverpod Provider	Endpoint principal	Feature clave
Dashboard	pendingActionsStreamProvider	GET /api/v1/dashboard	Realtime Supabase WS
Acciones	actionsProvider	GET/POST /api/v1/actions	Swipe + CSV export/import
Mapa/Plano	_warehouseQuickProvider	GET /api/v1/warehouse	CustomPainter real
Escanear	_scanResultProvider	POST /api/v1/scan	mobile_scanner + Vision
Agentes	_agentStatusProvider	GET /api/v1/agent/*	4 tabs: estado+runs
Proveedores	_suppliersProvider	GET /api/v1/suppliers	Merma historica + pedido IA
Almacen	_warehouseProvider	GET /api/v1/warehouse	FEFO + alertas caducidad
Informes	_reportsProvider	GET /api/v1/reports/*	11 tabs + PDF + ESG
Perfil/Config	userRoleProvider	GET/PUT /store/profile	GPS coords para weather

06 - Resultados y Metricas Reales

774/774	+83,3 pp	23/23	483,95 EUR	45	0,80 EUR
Tests 100% pass	Precision vs. baseline	Ataques bloqueados	Merma identificada	Acciones completadas	Coste/mes real

Suite de tests por modulo

Modulo	Tests	Pass	Tiempo	Cobertura
Evaluador (score 0-100)	89	89/89	0,14s	Todos los rangos, edge cases caducidad
Validador (23 ataques)	47	47/47	0,08s	Prompt injection, precio<coste, FEFO, bypass...
Consenso (regla 2/3)	42	42/42	0,12s	Empate, mayoria, caso arbitro Opus
Supervisor / Kuine	25	25/25	0,19s	Loop, tools, timeouts, errores BD
Chuwu agent	61	61/61	0,31s	Intent, callbacks, modo ruta, donacion
Database & API	38	38/38	0,42s	Todos los endpoints, auth, RLS
Scheduler	18	18/18	0,09s	15 jobs, horarios, quiet hours 21-8h
Otros modulos	454	454/454	0,63s	Price, stock, PDF, formateo, telegram_formatter
TOTAL	774	774/774	1,98s	Sin conexion real a Supabase/Claude API

Comparativa con soluciones del mercado

Criterio	MermaOps	Winnow V2	Orbisk	Manual
Coste implantacion	0 EUR	>20.000 EUR	>15.000 EUR	0 EUR
Coste operativo/mes	~0,80 EUR	~300 EUR	~250 EUR	~120 EUR
Hardware requerido	Ninguno	Bascula+cam	Camara+srv	Ninguno
Autonomia 24/7	Si (15 cron)	Parcial	Parcial	No
Precision	100% tests	N/D publico	N/D publico	16,7%
Normativa CSRD	Si (RAG)	No	No	No
Multi-agente IA	12 agentes	No	No	No
Extended thinking	Si	No	No	No

Datos operativos reales - Supabase demo-store-001

Verificable	
Todos los datos pueden consultarse en Supabase, tabla a tabla, sin estimaciones.	
Metrica	Valor real
Acciones completadas por empleados	45
Briefs diarios generados por Kuine	7
Decisiones tomadas por Kuine	15

Runs completos de Kuine (analisis tienda)	9
Registros en merma_log	45
Donaciones registradas	4
Valor de merma identificado	483,95 EUR
Valor donado (genera deduccion fiscal 35%)	69,40 EUR
Duracion media por run de Kuine	~6,3 min (377 segundos)
Coste estimado por brief diario (con caching)	~0,03 EUR
Coste total mensual estimado (1 tienda)	~0,80 EUR
ROI mensual estimado (merma evitada / coste)	>500:1

Metricas ESG y cumplimiento normativo CSRD 2026

Normativa	Cobertura	Agente que la aplica
Reglamento (CE) 178/2002	Seguridad alimentaria	Validador: nunca completar venta de caducado
RD 1334/1999	Etiquetado y caducidad	Evaluador: dias restantes vs. tipo producto
Ley 7/2022	Residuos/economia circular	ESG module: tracking CO2 evitado
Ley 49/2002 Art.20	Deduccion fiscal 35%	Donaciones: deduccion calculada automaticamente
CSRD 2026	Reporting ESG PYMEs	Modulo ESG: genera datos para informe obligatorio UE
WRAP Food Waste 2023	Benchmark 1,3% revenue	Benchmark: comparativa sector espanol
FAO Food Loss 2022	Recuperacion 28% total	Benchmark: tasa recuperacion vs. referencia FAO
Poore & Nemecek (2018)	CO2 por kg producto	ESG: calculo CO2 evitado por categoria
Mekonnen & Hoekstra (2011)	Agua por kg producto	ESG: calculo agua ahorrada por categoria

MermaOps

Sistema Multi-Agente de IA para Reduccion de Merma Alimentaria en Supermercados Espanoles



CE 178/2002 RD 1334/1999 Ley 7/2022 Ley 49/2002 CSRD 2026